

Identificación y selección de datasets para el entrenamiento del producto

El objetivo de este apartado es identificar conjuntos de datos que puedan emplearse para entrenar un modelo destinado a nuestro proyecto (es comercial). La selección que hemos hecho incluye repositorios con licencias **MIT**, **Apache 2.0**, **CC0** o **CC-BY**, totalmente compatibles con uso comercial.

A lo largo del proyecto utilizaremos cinco tipos de datasets, cada uno con un papel clave para que el robot entienda, razone y actúe correctamente. Los **datasets de lenguaje general** nos darán una base sólida para que el modelo comprenda descripciones, vocabulario y conceptos del mundo. Los **datasets de instrucciones** servirán para que aprenda a seguir órdenes paso a paso y se alinee con comportamientos útiles y seguros. Con los **datasets conversacionales** mejoraremos la capacidad del robot para interactuar de forma natural, entender matices y mantener turnos de diálogo. Los **datasets específicos de robótica** permitirán conectar el lenguaje con acciones físicas reales, enseñando al modelo cómo ejecutar tareas manipulativas o de navegación. Por último, si usamos comandos hablados, los **datasets de voz** harán posible reconocer órdenes verbales con distintos acentos y estilos. En conjunto, estos cinco grupos proporcionan todo lo necesario para que el modelo pueda comunicarse, comprender instrucciones y ejecutarlas de forma coherente en un robot humanoide.

A continuación, iremos mencionando cada uno de ellos y explicaremos su utilidad.

1. Datos lingüísticos generales:

The Pile: EleutherAI

URL: <https://pile.eleuther.ai/>

Licencia: MIT y CC-BY

Notas: Algunas partes del Pile tienen licencias mixtas, solo seleccionaremos las secciones con licencia MIT o CC-BY.

Utilidad: Base general de texto de alta calidad para entrenar modelos de lenguaje.

OpenWebText2 (LAION)

URL: <https://arxiv.org/abs/2210.08402>

Licencia: MIT

Descripción: Replica abierta de WebText, filtrada y lista para uso comercial.

Utilidad: Base general de texto de alta calidad para entrenar modelos de lenguaje.

“C4-en-clean” (Google / Hugging Face)

URL: <https://huggingface.co/datasets/allenai/c4>

Licencia: Apache 2.0

Descripción: Corpus limpio de Common Crawl.

Importante: Usaremos solo las porciones “clean”, que no incluyen material con copyright.

Utilidad: Base general de texto de alta calidad para entrenar modelos de lenguaje.

Wikipedia (dump completo)

URL: <https://dumps.wikimedia.org/>

Licencia: CC-BY-SA 3.0

Condición comercial: Permitido siempre que derivaciones indiquen la licencia y atribución.

Utilidad: Conocimiento estructurado y factual.

2. Datasets de instrucciones:

FLAN Collection

URL: <https://github.com/google-research/FLAN>

Licencia: Apache 2.0 / MIT (varía por subset, pero todos los seleccionados permiten uso comercial).

Utilidad: Instrucciones generalistas necesarias para robots que siguen órdenes.

OIG-small (LAION)

URL: <https://huggingface.co/datasets/laion/OIG>

Licencia: MIT

Importante: Usaremos OIG-small-curated (100% MIT).

Utilidad: Gran volumen de instrucciones y correcciones humanas.

Natural Instructions v2 (AllenAI)

URL: <https://github.com/allenai/natural-instructions>

Licencia: Apache 2.0

Utilidad: Más de 1.600 tipos de instrucciones anotadas.

3. Datos conversacionales

OpenAssistant Conversations (OASST1)

URL: <https://huggingface.co/datasets/OpenAssistant/oasst1>

Licencia: Apache 2.0

Utilidad: Conversaciones naturales de alta calidad.

DialogSum (versión comercial)

URL: <https://huggingface.co/datasets/knkarthick/dialogsum>

Licencia: Apache 2.0

Utilidad: Conversaciones estructuradas para desarrollar habilidades en el diálogo.

OpenSubtitles (solo sección CC0/CC-BY)

URL: <https://opus.nlpl.eu/OpenSubtitles/corpus/version/OpenSubtitles>

Licencia: CC-BY

Nota: Solo usar los idiomas y subconjuntos explícitamente marcados como CC-BY (descartando los no comerciales).

Utilidad: Diversidad lingüística y diálogos naturales.

4. Datos específicos para robótica

Open X-Embodiment Dataset (Google / CMU / Berkeley / Stanford)

URL: <https://robotics-transformer-x.github.io/>

Licencia: Apache 2.0

Utilidad: Datos sobre manipulación, acciones de robots reales y demostraciones.

BEHAVIOR-1K (Stanford)

URL: <https://behavior.stanford.edu/>

Licencia: BSD-3 (compatible con uso comercial)

Utilidad: Mil tareas domésticas descritas en lenguaje natural.

ManiSkill (Simulación de tareas)

URL: <https://github.com/haosulab/ManiSkill>

Licencia: Apache 2.0

Utilidad: Manipulación robótica y escenarios simulados.

RoboCap / RoboSet (Hugging Face)

URL: <https://huggingface.co/datasets/jdvakil/RoboSet-Teleoperation>

Licencia: Apache 2.0

Utilidad: Acciones, trayectorias y descripciones textuales para robots manipuladores.

5. Audio y voz

Mozilla Common Voice

URL: <https://commonvoice.mozilla.org/datasets>

Licencia: CC0

Utilidad: Perfecto para reconocimiento de órdenes habladas.

LibriSpeech

URL: <https://www.openslr.org/12/>

Licencia: CC-BY 4.0

Utilidad: Datos limpios para reconocimiento de voz.

6. Datos faltantes y cómo generarlos

Aunque los datasets anteriores permiten entrenar un modelo robusto, hay ciertas carencias que requerirán datos propios si el proyecto se quisiera sacar adelante.

Faltarían instrucciones específicas en entorno concreto, demostraciones de manipulación real, conversaciones realistas y escenarios de seguridad (limitaciones, fallos, manejo de objetos frágiles...).

Para solventar esto haremos lo siguiente:

- Grabaremos demostraciones en vídeo (propias) con anotaciones manuales.
- Generaremos instrucciones propias (programada).
- Simularemos miles de pruebas.
- Registraremos comandos hablados reales.