

## EVALUACIÓN DE MODELO

El sistema ISA-Home, al ser una plataforma modular que combina robótica, procesamiento del lenguaje e interacción en el hogar , y siendo explícitamente **clasificado como un Sistema de Alto Riesgo bajo la AI Act**, requiere una estrategia de evaluación multifacética que priorice la seguridad, la robustez y el cumplimiento normativo por encima del rendimiento puro.

La evaluación no se centrará en un único modelo, sino en un **sistema de sistemas**. A continuación, se detalla el plan de evaluación.

### Métricas de Rendimiento Específicas por Módulo

Dividimos la evaluación conforme a los componentes funcionales de ISA-Home:

| Módulo y Tarea                                  | Métrica Principal                                                                                                  | Métrica Secundaria (Seguridad/Robustez)                                                                                     | Justificación de la Métrica                                                                    |
|-------------------------------------------------|--------------------------------------------------------------------------------------------------------------------|-----------------------------------------------------------------------------------------------------------------------------|------------------------------------------------------------------------------------------------|
| <b>Módulo 1: Base (Navegación y Percepción)</b> |                                                                                                                    |                                                                                                                             |                                                                                                |
| Tarea: SLAM y Navegación (LiDAR/Cámara)         | <b>Tasa de Éxito de Tarea (TSR):</b> % de veces que la base llega al destino solicitado sin intervención.          | <b>Tasa de Colisión (CR):</b> % de fallos de navegación que resultan en contacto físico. Debe ser 0% para humanos/mascotas. | Mide la fiabilidad básica (TSR) y la seguridad física fundamental (CR) en un entorno dinámico. |
| Tarea: Reconocimiento 3D de Personas            | <b>mAP (mean Average Precision):</b> Precisión en la detección y clasificación de (adulto, niño, invitado, mayor). | <b>Tasa de Falsos Negativos (FNR) para Menores:</b> % de veces que un menor no es detectado o es mal clasificado.           | Crítico para la "línea roja" de no interacción y para adaptar el perfil de seguridad.          |

|                                                          |                                                                                                                                                 |                                                                                                                                          |                                                                                                             |
|----------------------------------------------------------|-------------------------------------------------------------------------------------------------------------------------------------------------|------------------------------------------------------------------------------------------------------------------------------------------|-------------------------------------------------------------------------------------------------------------|
| Tarea:<br>Reconocimiento de<br>Objetos                   | <b>F1-Score:</b> Para<br>objetos clave (ej.<br>"estación<br>PowerNest",<br>"cuchillo", "vaso de<br>cristal").                                   | <b>Equidad de Detección:</b><br>Disparidad en la precisión<br>de detección bajo diferentes<br>condiciones de iluminación<br>(día/noche). | Esencial para la<br>recarga<br>autónoma, la<br>manipulación<br>segura y la<br>operación 24/7.               |
| <b>Módulo 2: Brazos<br/>Robóticos<br/>(Manipulación)</b> |                                                                                                                                                 |                                                                                                                                          |                                                                                                             |
| Tarea: Tareas de<br>Precisión (Cocina)                   | <b>Tasa de<br/>Finalización de<br/>Tarea (TCR):</b> % de<br>tareas (ej. "batir un<br>huevo", "coger un<br>tomate")<br>completadas con<br>éxito. | <b>Adherencia al Límite de<br/>Fuerza (FLA):</b> 0<br>instancias de fuerza<br>aplicada > 2.5 kg.                                         | Mide la utilidad<br>real (TCR) y la<br>seguridad física<br>directa (FLA)<br>para evitar<br>roturas o daños. |
| Tarea: Acople de<br>Conectores (ISA<br>Connectors)       | <b>Tasa de Éxito de<br/>Acople (DSR):</b> %<br>de intentos exitosos<br>de desacople y<br>acople de los<br>brazos.                               | <b>Error Medio Absoluto<br/>(MAE) de Fuerza:</b><br>Desviación media del<br>sensor de presión durante el<br>acople.                      | Garantiza la<br>modularidad y la<br>seguridad en el<br>mantenimiento<br>de los propios<br>brazos.           |
| <b>Módulo 3:<br/>Software (Voz y<br/>Privacidad)</b>     |                                                                                                                                                 |                                                                                                                                          |                                                                                                             |
| Tarea:<br>Reconocimiento de<br>Voz (ISA-Points)          | <b>Word Error Rate<br/>(WER):</b> % de<br>palabras transcritas<br>incorrectamente.                                                              | <b>WER en Entornos<br/>Ruidosos:</b> WER con ruido<br>de fondo (cocina, TV,<br>aspiradora ).                                             | Mide la precisión<br>de la<br>transcripción,<br>vital para la<br>usabilidad en un<br>hogar real.            |

|                                         |                                                                                                                             |                                                                                                                                          |                                                                                                           |
|-----------------------------------------|-----------------------------------------------------------------------------------------------------------------------------|------------------------------------------------------------------------------------------------------------------------------------------|-----------------------------------------------------------------------------------------------------------|
| Tarea: Comprensión del Lenguaje (NLU)   | <b>Precisión de Intención (Intent Accuracy):</b> % de comandos cuya intención (ej. "limpiar", "cocinar") es bien entendida. | <b>Tasa de Falsos Negativos (FNR) para Comandos de Emergencia:</b> % de veces que un comando de parada ("¡ISA, PARA!") no es reconocido. | <b>Esta es la métrica de seguridad más crítica del NLU.</b> Un fallo aquí anula el sistema de emergencia. |
| Tarea: Privacidad (Procesamiento Local) | <b>Tasa de Fuga de Datos (DLR):</b> 0%                                                                                      | <b>Latencia de Procesamiento Local:</b> Tiempo de respuesta (ms) desde el comando de voz hasta la acción.                                | Métrica de cumplimiento (DLR) que debe ser cero. La latencia (rendimiento) es secundaria a la privacidad. |

## **Benchmarks Existentes y Propios**

Dado que ISA-Home es un producto específico, usaremos una combinación de benchmarks públicos (para pre-entrenamiento) y benchmarks internos (para validación de seguridad).

### **1. Benchmarks Públicos (Pre-entrenamiento):**

- **Navegación/Percepción:** *Matterport3D* y *ScanNet* para el entrenamiento de reconocimiento de escenas y objetos 3D en interiores.
- **Manipulación:** *RoboNet* y *TidyBot* para el entrenamiento de agarre y manipulación de objetos domésticos y tareas de limpieza.
- **Voz:** *Common Voice (Mozilla)* y *Librispeech* para el entrenamiento base del modelo ASR (Reconocimiento de Voz).

### **2. Benchmarks Internos (Validación y "Go/No-Go"):**

- **"ISA-Home Digital Twin":** Un entorno de simulación 3D de alta fidelidad que replica 5 tipos de hogares (ej. familia con niños, pareja de personas mayores, piso de estudiantes). Aquí se probarán millones de escenarios de navegación para medir la Tasa de Colisión (CR) antes del despliegue físico.
- **"Corpus ISA-Commands-v1":** Un dataset de audio grabado *in-situ* usando los ISA-Points en entornos reales con ruido. Incluirá 500 locutores con diferentes acentos, edades y un subconjunto específico de comandos de emergencia susurrados, gritados y con ruido de fondo.
- **"The Gauntlet" (Banco de Pruebas Físico):** Un banco de pruebas para los brazos robóticos con objetos de fragilidad variable (huevos, copas de cristal, latas) para validar el límite de 2.5kg y la Tasa de Finalización de Tareas (TCR).

## **Umbrales de Decisión ("Go/No-Go") para Producción**

Siendo un sistema de Alto Riesgo, los umbrales de "Go/No-Go" son binarios para la seguridad y basados en rendimiento para la usabilidad.

### **NO-GO (PARADA INMEDIATA)**

El despliegue a producción se cancelará (NO-GO) si falla **CUALQUIERA** de los siguientes criterios de seguridad:

1. **Fallo de Sistema de Emergencia:** 100% de éxito requerido. FNR < 0.001% para comandos de parada en el "Corpus ISA-Commands-v1".
2. **Violación de Líneas Rojas:** 100% de éxito requerido. 0 instancias de interacción no autorizada con menores en el "Digital Twin".
3. **Seguridad Física (Humanos):** Tasa de Colisión (CR) < 0.001% con humanos o mascotas en el "Digital Twin".
4. **Seguridad Física (Brazos):** 0 instancias (FLA=100%) donde se exceda el límite de fuerza de 2.5kg en "The Gauntlet".
5. **Violación de Privacidad:** Tasa de Fuga de Datos (DLR) > 0%. Cualquier dato sensible (voz, imagen) enviado a la nube sin consentimiento explícito.
6. **Fallo de Componente Crítico:** 100% de éxito requerido en la detección de componentes dañados.

### **GO (APROBADO PARA PRODUCCIÓN)**

El despliegue se autoriza (GO) si se cumplen **TODOS** los criterios de NO-GO y, adicionalmente, se alcanzan los siguientes umbrales de rendimiento:

1. **Navegación:** TSR > 95% en destinos comunes (ej. "a la PowerNest" ) y CR < 1% para objetos no críticos (ej. patas de silla).
2. **Voz:** WER < 15% en entornos ruidosos. Precisión de Intención > 98% para las 50 tareas más comunes.
3. **Manipulación:** TCR > 90% para tareas clave de cocina y limpieza.
4. **Equidad (Fairness):** Disparidad en el mAP de reconocimiento de personas < 2% entre diferentes tonos de piel y alturas (niños vs. adultos)