

Estimación de coste, consumo energético y huella de carbono para el entrenamiento del modelo

El objetivo de este documento es estimar el número de operaciones necesarias para entrenar un modelo de lenguaje con 1.000 millones de parámetros, así como calcular el consumo energético total, las emisiones de CO2 y el coste económico aproximado si se entrena utilizando hardware disponible actualmente. También, se presenta la influencia del número de iteraciones de desarrollo, que habitualmente incrementa el coste total entre un 50% y un 200%.

1. Tamaño del modelo y conjunto de entrenamiento

Para este análisis se ha elegido un modelo de 1.000 millones de parámetros (1B) entrenado con un conjunto de datos equivalente a 200.000 millones de tokens (200B). Esta configuración la hemos elegido ya que: responde a un equilibrio entre capacidad predictiva, viabilidad técnica y limitaciones. Los modelos de un billón de parámetros representan son muy utilizados hoy en proyectos de investigación, permiten capturar patrones complejos del lenguaje sin alcanzar costes exagerados. Además, entrenarlos resulta viable tanto con una única GPU potente como con un pequeño clúster, lo que reduce de forma significativa los tiempos de experimentación y riesgos.

El volumen de datos seleccionado (200B tokens) también se ajusta a las recomendaciones actuales sobre la relación entre tamaño del modelo y tamaño del conjunto de entrenamiento. Un modelo de estas dimensiones tiende a beneficiarse de entrenamientos con cientos de miles de millones de tokens, ya que este rango permite extraer información diversa sin caer en un sobreajuste. También, este tamaño de dataset evita entrar en consumos energéticos extremadamente elevados, algo que ocurre cuando se superan los billones de tokens. En conjunto, esta elección busca situar el entrenamiento dentro de un escenario realista, con un coste energético, económico y ambiental.

2. Cálculo del número total de operaciones (FLOPs)

Fórmula para estimar el número de operaciones totales necesarias para entrenar un transformer desde cero:

$$\text{FLOPs totales} = 6 \times N \times D$$

donde N es el número de parámetros del modelo y D el número de tokens del conjunto de entrenamiento.

Aplicando la fórmula:

- $N = 1 \times 10^9$
- $D = 2 \times 10^{11}$
- $\text{FLOPs} \approx 6 \times 10^9 \times 2 \times 10^{11} = \mathbf{1,2 \times 10^{21} \text{ FLOPs}}$

Esta cifra representa el total de operaciones de punto flotante que el hardware debe procesar durante un entrenamiento completo.

3. Rendimiento real de la GPU y horas de cómputo

Tomamos como referencia la GPU NVIDIA H100, actualmente uno de los aceleradores más utilizados para entrenar modelos de IA. Aunque su rendimiento teórico es muy alto, en la práctica la eficiencia durante el entrenamiento suele rondar el 40% (respecto al pico).

A partir de los datos, y tras aplicar el factor de eficiencia, el tiempo necesario para procesar los $1,2 \times 10^{21}$ FLOPs se estima en unas **421 horas-GPU** (equivalente a unos 17,5 días continuos con una sola GPU H100).

1. FLOPs totales del entrenamiento: $\mathbf{1,2 \times 10^{21}}$
2. Rendimiento teórico H100: $\mathbf{1,979 \times 10^{15} \text{ FLOPs/s}}$
3. Rendimiento real estimado (40%): $\mathbf{7,916 \times 10^{14} \text{ FLOPs/s}}$
4. Tiempo = FLOPs / rendimiento = $\mathbf{1,515 \times 10^6 \text{ s}}$
5. Tiempo en horas = **421 horas-GPU**

4. Consumo energético aproximado

La potencia de una GPU H100 se sitúa en torno a 350 W. Para reflejar el consumo real del centro de datos (refrigeración, pérdidas...) se aplica el índice PUE (Power Usage Effectiveness) de 1,2, un valor aproximado de los centros de datos actuales.

Potencia efectiva utilizada en los cálculos: **0,48 kW por GPU**

Consumo energético total: $\mathbf{421 \text{ h} \times 0,48 \text{ kW} = 202 \text{ kWh}}$

Este consumo es similar al gasto eléctrico total de una casa durante dos o tres semanas.

5. Huella de carbono

La conversión de energía eléctrica a emisiones depende de la composición de la red eléctrica. En nuestro caso, en España, los valores recientes sitúan la media anual alrededor de: **108 g CO2 por kWh**

Aplicando esto:

$$\text{Emisiones} = 202 \text{ kWh} \times 0,108 \text{ kg/kWh} = 21,8 \text{ kg CO}_2$$

Esto equivale aproximadamente a las emisiones generadas por un coche de gasolina en un recorrido de unos 175 km.

6. Coste económico del entrenamiento

El precio por hora de una GPU H100 varía de manera importante según el proveedor de servicios en la nube. Nosotros usaremos uno muy alto para garantizar la calidad del producto:

- Rondará **11 USD/h.**

Por tanto, el coste del entrenamiento será:

- $421 \text{ h} \times 11 \text{ USD} = \mathbf{4.632 \text{ USD}}$

7. Impacto del número de iteraciones de desarrollo

Normalmente no se ejecuta un único entrenamiento final. Los ajustes de hiperparámetros, pruebas, errores y experimentos adicionales hacen que el coste total aumente entre un 50% y un 200%.

Aplicando ese factor:

- **Coste total mínimo ($\times 1,5$): 6.948 USD**
- **Coste total máximo ($\times 3$): 13.896 USD**

Conclusión:

El escenario definido (un modelo de 1B parámetros) representa una opción equilibrada para nuestro proyecto. El coste económico es razonable para un proyecto de esta escala, el consumo energético es moderado y la huella de carbono queda muy por debajo de la de proyectos comerciales menos familiarizados con el medioambiente.

REFERENCIAS:

Fórmulas y estimaciones de FLOPs

- [“Scaling Laws for Neural Language Models”](#) La fórmula $6 \times N \times D$.

Especificaciones de la GPU NVIDIA H100, potencia eléctrica y consumo

- [NVIDIA H100 Tensor Core GPU Architecture](#)

Precios por hora de GPU en la nube

- [Catálogos de proveedores.](#)

Factores PUE (Power Usage Effectiveness)

- [Eficiencia de centros de datos.](#)

Emisiones eléctricas en España

- [Emisiones eléctricas.](#)