

Anexo de Datos y Entrenamiento

1. Composición del Entrenamiento

El entrenamiento del modelo fundacional de ISA-Home (1B parámetros) se basa en un enfoque híbrido que combina grandes volúmenes de datos de lenguaje natural con datasets específicos de robótica e interacción humana. Se ha priorizado el uso de fuentes con licencias comerciales permisivas (MIT, Apache 2.0, CC-BY) para garantizar la viabilidad legal del producto.

El corpus total estimado es de **200.000 millones de tokens**, distribuidos en las siguientes categorías funcionales:

- A) Datos Lingüísticos Generales (Base de Conocimiento)** Su objetivo es dotar al modelo de comprensión del mundo, gramática y razonamiento básico.
 - **The Pile (EleutherAI):** Secciones seleccionadas con licencia MIT/CC-BY. (url: <https://pile.eleuther.ai/>)
 - **OpenWebText2 (LAION):** Réplica abierta de WebText filtrada para uso comercial. (licencia MIT) (url: <https://arxiv.org/abs/2210.08402>)
 - **C4-en-clean (Google/Hugging Face):** Versión limpia del Common Crawl, excluyendo material con copyright restrictivo. (licencia Apache 2.0) (url: <https://huggingface.co/datasets/allenai/c4>)
- B) Datos de Instrucciones (Capacidad de Seguimiento)** Entrenan al modelo para seguir órdenes complejas paso a paso y alinearse con la intención del usuario.
 - **FLAN Collection:** Subsets con licencia Apache 2.0 para generalización de tareas. (también subsets con licencia MIT) (url: <https://github.com/google-research/FLAN>)
 - **OIG-small (LAION):** Versión "curated" (100% MIT) para instrucciones y correcciones humanas. (url: <https://huggingface.co/datasets/laion/OIG>)
 - **Natural Instructions v2:** Más de 1.600 tipos de tareas anotadas. (licencia Apache 2.0) (url: <https://github.com/allenai/natural-instructions>)
- C) Datos Conversacionales (Interacción Natural)**
 - **OASST1 (OpenAssistant):** Diálogos de alta calidad supervisados por humanos. (licencia Apache 2.0) (url: <https://huggingface.co/datasets/OpenAssistant/oasst1>)
 - **DialogSum:** Conversaciones estructuradas para gestión de turnos y resumen. (licencia Apache 2.0) (url: <https://huggingface.co/datasets/knkarthick/dialogsum>)

- **OpenSubtitles:** Diversidad lingüística y diálogos naturales. (solo secciones con licencia CC0 / CC BY)
(url: <https://opus.nlpl.eu/OpenSubtitles/corpus/version/OpenSubtitles>)

D) Datos de Robótica y Acción (Grounding Físico) Conectan el procesamiento del lenguaje con acciones físicas reales en el entorno 3D.

- **Open X-Embodiment:** Datos masivos de manipulación y trayectorias de robots reales. (licencia Apache2.0) (url: <https://robotics-transformer-x.github.io/>)
- **BEHAVIOR-1K:** Simulación de 1.000 tareas domésticas descritas en lenguaje natural. (licencia BSD-3) (url: <https://behavior.stanford.edu/>)
- **ManiSkill & RoboSet:** Datos de teleoperación y escenarios simulados de manipulación. (licencias Apache 2.0)
(urls: <https://github.com/haosulab/ManiSkill> ,
<https://huggingface.co/datasets/jdvakil/RoboSet-Teleoperation>)

E) Datos de Audio y Voz (Interacción Verbal)

- **Mozilla Common Voice & LibriSpeech:** Datos multilingües bajo licencia CC0/CC-BY para robustez en reconocimiento de voz (ASR).
(urls: <https://commonvoice.mozilla.org/datasets> ,
<https://www.openslr.org/12/>)

2. Generación de Datos Sintéticos y Propios

Para cubrir vacíos críticos donde no existen datasets públicos (situaciones de seguridad doméstica específicas o manipulación de objetos frágiles), se implementa una estrategia de generación interna:

- **Simulación en "Digital Twin":** Generación de miles de escenarios de navegación y fallo en un entorno 3D de alta fidelidad.
- **Grabación In-situ:** Creación del cuerpo de los ISA-Comandos, registrando comandos de voz reales con ruido de fondo (aspiradoras, TV) y variaciones de estrés vocal (gritos de emergencia).
- **Teleoperación:** Grabación de demostraciones de vídeo propias con anotaciones manuales para tareas finas.

3. Estimación de Recursos y Huella Ambiental

Basado en un modelo de 1.000 millones de parámetros (1B) y el cuerpo de 200B tokens:

- **Cómputo Total Requerido:** $1,2 \times 10^{21}$ FLOPs.
- **Hardware de Referencia:** GPU NVIDIA H100 (Eficiencia estimada del 40% en entrenamiento real).
- **Tiempo de Entrenamiento:** 421 horas-GPU (aprox. 17,5 días en una sola H100).
- **Consumo Energético:** 202 kWh, similar al gasto eléctrico total de una casa durante dos o tres semanas.
- **Huella de Carbono:** 21,8 kg CO₂, calculado sobre la electricidad española (108g CO₂/kWh). Esto equivale a un trayecto de apenas 175 km en un vehículo de combustión, demostrando la eficiencia del enfoque de nuestro modelo frente a modelos masivos.
- **Coste Estimado:** Entre 4.600 USD y 13.900 USD, dependiendo del número de iteraciones y reentrenamientos necesarios.

REFERENCIAS A OTROS ARCHIVOS DEL PROYECTO:

- [Sprint 4/Mejoras/Datasets v1.1.pdf](#)
- [Sprint 3/Hardware energía coste huella de carbono v1.pdf](#)

REFERENCIAS EXTRA:

Fórmulas y estimaciones de FLOPs

- [“Scaling Laws for Neural Language Models”](#) La fórmula $6 \times N \times D$.

Especificaciones de la GPU NVIDIA H100, potencia eléctrica y consumo

- [NVIDIA H100 Tensor Core GPU Architecture](#)

Precios por hora de GPU en la nube

- [Catálogos de proveedores.](#)

Factores PUE (Power Usage Effectiveness)

- [Eficiencia de centros de datos.](#)

Emisiones eléctricas en España

- [Emisiones eléctricas.](#)

