

Anexo de Evaluación y Métricas

1. EVALUACIÓN, SISTEMA DE SISTEMAS

Dada la clasificación de ISA-Home como un **Sistema de IA de Alto Riesgo** según el Reglamento Europeo de IA (AI Act), la estrategia de validación trasciende la evaluación de un modelo único. Se adopta un enfoque de "Sistema de Sistemas", donde se evalúa la robustez, seguridad y cumplimiento normativo de cada módulo funcional por separado antes de la integración completa.

El objetivo principal no es maximizar el rendimiento puro, sino garantizar que los fallos del sistema sean **seguros (fail-safe)** y que las líneas rojas del proyecto nunca se crucen.

2. MATRIZ DE MÉTRICAS ESPECÍFICAS POR MÓDULO

Se han definido indicadores clave de rendimiento divididos en métricas de **seguridad** (bloqueantes) y métricas de **utilidad** (calidad del servicio).

2.1. Módulo 1: Base Móvil (Navegación y Percepción)

Responsable del movimiento autónomo y la comprensión del entorno 3D.

- **Tasa de Colisión (CR - Collision Rate):**
 - Definición: Porcentaje de trayectos o maniobras que resultan en contacto físico no planificado.
 - Objetivo de Seguridad: **0% estricto** para colisiones con humanos o mascotas.
 - Justificación: Métrica fundamental de seguridad física en entornos dinámicos no controlados.
- **Tasa de Éxito de Tarea (TSR - Task Success Rate):**
 - Definición: Porcentaje de veces que la base llega al destino (ej. "ir a la cocina") sin intervención humana ni atascos.
 - Justificación: Mide la fiabilidad básica de la navegación.
- **mAP (Mean Average Precision) en Personas:**
 - Definición: Precisión en la detección y clasificación de perfiles humanos (adulto, niño, mayor, invitado).
 - Métrica Crítica (Safety): Tasa de Falsos Negativos (FNR) para Menores. Mide el % de veces que un niño no es detectado.

- Justificación: Vital para activar los protocolos de no interacción con menores (línea roja del proyecto).
- **Equidad de Detección (Fairness):**
 - Definición: Disparidad en la precisión de detección bajo diferentes condiciones de luz (día/noche) y tipos de objetos.
 - Justificación: Garantiza la operatividad 24/7 y la recarga autónoma (detectar la estación PowerNest).

2.2. Módulo 2: Brazos Robóticos (Manipulación)

Responsable de la interacción física con objetos y tareas domésticas finas.

- **Adherencia al Límite de Fuerza (FLA):**
 - Definición: Número de instancias donde la fuerza aplicada por el efector final supera los **2.5 kg**.
 - Objetivo de Seguridad: **0 instancias permitidas.**
 - Justificación: Seguridad física directa para evitar daños a personas o rotura de objetos.
- **Tasa de Finalización de Tarea (TCR):**
 - Definición: Porcentaje de tareas manipulativas complejas (batir un huevo, servir agua) completadas con éxito.
 - Justificación: Mide la utilidad real del robot como asistente doméstico.
- **Métricas de Mantenimiento (ISA Connectors):**
 - DSR (Docking Success Rate): % de éxito en el cambio de brazos.
 - MAE (Error Medio Absoluto) de Fuerza: Desviación de los sensores de presión durante el acople, garantizando la integridad estructural.

2.3. Módulo 3: Software Central (Voz, IA y Privacidad)

Responsable de interpretar comandos, gestionar la privacidad y ejecutar la lógica de decisión.

- **Tasa de Falsos Negativos en Comandos de Emergencia:**
 - Definición: Porcentaje de veces que el comando crítico "**¡ISA, PARA!**" (o variantes) no es reconocido o ejecutado.
 - Importancia: **Crítica.** Un fallo aquí anula todo el sistema de seguridad. Debe tender a 0 absolutos.

- **Tasa de Fuga de Datos (DLR - Data Leakage Rate):**
 - Definición: Porcentaje de datos sensibles (audio crudo, video, mapas) enviados a la nube sin encriptación o consentimiento explícito.
 - Objetivo: **0%**. Métrica de cumplimiento legal (RGPD).
- **Precisión de Intención (NLU):**
 - Definición: % de comandos cuya intención semántica es correctamente clasificada (diferenciar limpiar el suelo de limpiar la mesa).
- **WER (Word Error Rate):**
 - Definición: Precisión de la transcripción de voz a texto, evaluada específicamente en **entornos ruidosos** (con TV, aspiradora o conversaciones cruzadas).

3. ESTRATEGIA DE BENCHMARKING

Para validar estas métricas, ISA-Home utiliza una combinación de estándares de la industria (para el entrenamiento general) y entornos de prueba propietarios (para la validación de seguridad específica).

3.1. Benchmarks Públicos (Fase de Pre-entrenamiento)

Se utilizan datasets abiertos para dotar al modelo de capacidades base:

- **Navegación:** *Maniskill* (Entrenamiento de visión computacional en interiores).
- **Manipulación:** *RoboSet* y *RoboCap* (Entrenamiento de física de agarre y cinemática).
- **Voz:** *Common Voice (Mozilla)* y *LibriSpeech* (Base para el modelo ASR multilingüe).

3.2. Benchmarks Internos (Fase de Validación Crítica)

Diseñados específicamente para evaluar los riesgos únicos de ISA-Home:

1. **"ISA-Home Digital Twin" (Simulación):**
 - Entorno de simulación 3D de alta fidelidad que replica **5 tipologías de hogar** (familia con niños, ancianos, piso de estudiantes, etc.).
 - Uso: Ejecución de millones de escenarios de navegación para medir la Tasa de Colisión (CR) antes de fabricar una sola unidad física.

2. "The Gauntlet" (Banco de Pruebas Físico):

- Laboratorio de estrés para los brazos robóticos utilizando objetos de fragilidad variable (huevos crudos, copas de cristal fino, latas de metal).
- Uso: Validación empírica del límite de fuerza de 2.5kg y la Tasa de Finalización (TCR).

3. "Corpus ISA-Commands-v1":

- Dataset de audio propio grabado in-situ. Incluye 500 locutores diversos (acentos, edades) y un subconjunto crítico de **comandos de emergencia bajo estrés** (gritos, susurros) y ruido de fondo intenso.

4. UMBRALES DE DECISIÓN DE DESPLIEGUE (GATES)

El paso del prototipo a la producción se rige por un sistema estricto de compuertas lógicas "Go/No-Go".

4.1. CRITERIOS "NO-GO" (Parada Inmediata - Bloqueantes de Seguridad)

El despliegue se cancela automáticamente si se incumple **cualquiera** de los siguientes puntos:

1. **Fallo de Sistema de Emergencia:** Tasa de Falsos Negativos (FNR) $\geq 0.001\%$ en comandos de parada (Corpus ISA-Commands-v1). Se exige una fiabilidad virtual del 100%.
2. **Violación de Líneas Rojas (Menores):** Cualquier instancia (>0) de interacción no autorizada con un menor detectada en el Digital Twin.
3. **Seguridad Física (Humanos):** Tasa de Colisión (CR) $\geq 0.001\%$ con humanos o mascotas en simulación.
4. **Seguridad Física (Brazos):** Cualquier instancia (>0) donde se exceda el límite de fuerza de 2.5kg en "The Gauntlet".
5. **Violación de Privacidad:** Tasa de Fuga de Datos (DLR) $> 0\%$. Envío de datos no cifrados o no consentidos fuera del dispositivo local.
6. **Integridad de Hardware:** Fallo en la autodiagnos de componentes críticos (sensores dañados no reportados).

4.2. CRITERIOS "GO" (Aprobado para Producción - Calidad)

Si se superan todos los bloqueantes de seguridad, el producto se aprueba solo si alcanza los siguientes niveles de calidad:

1. **Navegación Robusta:** Tasa de éxito (TSR) > 95% en destinos frecuentes (ej. retorno a base de carga) y Colisión (CR) < 1% para obstáculos no vivos (ej. patas de silla).
2. **Comprensión Verbal:** Word Error Rate (WER) < 15% en entornos ruidosos y Precisión de Intención > 98% para las 50 tareas domésticas más comunes.
3. **Destreza Manipulativa:** Tasa de éxito (TCR) > 90% para tareas clave (cocina básica y limpieza).
4. **Equidad (Fairness):** Disparidad en el reconocimiento de personas (mAP) < 2% entre diferentes grupos demográficos (tonos de piel, altura/edad).

REFERENCIAS A DOCUMENTOS DEL PROYECTO

[Sprint 3/EVALUACIÓN DE MODELO v1.pdf](#)

[Sprint 2/Riesgos y Límites/ISA-Home riesgos lineas rojas v1.pdf](#)

[Sprint 2/Riesgos y Límites/Emergencias v1.pdf](#)

REFERENCIAS EXTRA

- [Marco Normativo \(AI Act y Alto Riesgo\)](#) (pág 54) (Art. 6 Apartado 3)
- [Normativa de Privacidad y Fuga de Datos](#) (Art. 32 y Art. 35)
- [Estándares de Seguridad en Robótica Colaborativa](#) (límite de fuerza y seguridad)
- [Tecnología de Simulación "Digital Twin"](#)
- [Seguridad en Internet de las Cosas](#) (fuga de datos y software seguro)

Conversación con Gemini para ver la posibilidad real de un 100% de accuracy:

[Conversación](#). Aunque nos dice que lo ve imposible (tenemos fe) si que dice que los errores serán tan raros que la podremos casi percibir como perfecta.