

Análisis crítico del debate - Sprint 3:

A continuación se presentan las preguntas recibidas durante el debate, junto con una respuesta más elaborada y fundamentada que amplía lo que ya está recogido en el Sprint 3, y demuestra que se han considerado críticamente los posibles riesgos y mitigaciones.

- Pregunta 1

¿Por qué el equipo decidió desarrollar un modelo desde cero en lugar de adaptar o refinar modelos ya entrenados, considerando que esto incrementa el coste computacional y económico?

Nuestra decisión estratégica de entrenar un modelo propio ("Small Language Model" de 1B de parámetros) en lugar de depender de APIs de terceros (como GPT-4) responde a tres necesidades críticas: **privacidad, latencia y especialización**.

- **Arquitectura Edge (Local):** Los modelos comerciales masivos requieren nube. Nosotros necesitamos un modelo eficiente que pueda ejecutarse en el hardware local del robot para garantizar que los datos sensibles (vídeo/audio del hogar) nunca salgan de la casa.
- **Seguridad Física:** Un modelo generalista no está optimizado para la robótica. Entrenando desde cero con datasets específicos como *Open X-Embodiment* y *RoboSet*, alineamos el modelo específicamente para conectar lenguaje con acción física segura, algo que un LLM de chat no sabe hacer nativamente
- **Coste a largo plazo:** Aunque el entrenamiento inicial es costoso (estimado en unos 4.600 - 13.900 USD), el coste de inferencia recurrente de pagar una API por cada comando durante la vida útil del robot sería mucho mayor y menos sostenible.

- Pregunta 2

¿Cómo justificáis que los modelos actuales no son suficientes para vuestro caso de uso, teniendo en cuenta que entrenar uno nuevo aumenta notablemente la huella ambiental?

Los modelos actuales son insuficientes porque priorizan la generación de texto sobre la **seguridad operativa** y la **privacidad estricta**. Respecto a la huella ambiental, hemos realizado una estimación precisa: el entrenamiento de nuestro modelo de 1B parámetros genera aproximadamente **21,8 kg de CO2**. Esta cifra es enana comparada con el consumo energético continuo de enviar gigabytes de vídeo a la nube para ser procesados por modelos masivos (trillones de parámetros) durante años. Nuestro enfoque de "IA en el borde" (Edge AI) y un modelo compacto es, de hecho, la opción más ecológica a largo plazo para un despliegue masivo, alineándose con una huella razonable.

- **Pregunta 3**

Dado el reciente ataque sufrido por Anthropic, ¿cómo podéis asegurar que atacantes creativos no conseguirán vulnerar vuestro sistema?

Ningún sistema es invulnerable, por lo que nuestra defensa no se basa solo en software, sino en **seguridad por diseño a nivel de hardware** y una estrategia de "Sistema de Sistemas".

- **Protección Hard-wired:** Implementamos indicadores físicos (LEDs) que cierran el circuito eléctrico de la cámara/micrófono. Si un hacker lograra entrar por software, no podría espiarnos sin encender la luz, alertando al usuario.
- **Aislamiento:** Al priorizar el procesamiento local, reducimos la superficie de ataque al eliminar la base de datos centralizada de vídeos de usuarios.
- **Protocolo de Parada:** Ante cualquier anomalía o detección de intrusión, el sistema entra en modo "emergencia", cortando motores y conexiones.

- **Pregunta 4:**

En un entorno doméstico real, donde pueden ocurrir eventos inesperados (como que un perro salte sobre el robot), ¿cómo podéis plantear un objetivo cercano al 100% de éxito sin que sea inalcanzable?

Es vital distinguir entre "éxito de la tarea" y "éxito de la seguridad". Si un perro salta sobre el robot, no esperamos que el robot siga limpiando como si nada (eso sería irreal). Nuestro objetivo de **100% de éxito se refiere a la respuesta de seguridad**: detectar la colisión o el obstáculo imprevisto y detenerse inmediatamente sin causar daño. Para validar esto, utilizamos el "*ISA-Home Digital Twin*", donde simulamos millones de escenarios caóticos (incluyendo mascotas y niños) antes de fabricar una sola unidad. La "perfección" que buscamos es que el **robot nunca sea el causante** de un accidente, no que sea infalible realizando tareas en medio del caos.

- **Pregunta 5**

En escenarios no controlados, ¿no estáis estableciendo unos límites de despliegue que en la práctica resultan imposibles de cumplir?

Nuestros umbrales de despliegue ("Go/No-Go") son binarios para la seguridad, pero flexibles para la utilidad. Establecemos que una **Tasa de Colisión > 0% con humanos es un NO-GO absoluto**. Esto no es imposible; los robots industriales y los coches autónomos operan bajo principios similares. Si el entorno es tan incontrolable que el robot no puede moverse sin riesgo, el protocolo correcto es que no se mueva. Preferimos un producto que se detenga a menudo por precaución (fallo de utilidad) a uno que arriesgue la integridad física por intentar cumplir una tarea (fallo de seguridad). Además creemos que estos umbrales son alcanzables para 2029, estamos de acuerdo con el reputado **Leopold Aschenbrenner** (Ex-investigador del equipo de Superalineación de OpenAI), quien dice, en el documento [*Situational Awareness: The Decade Ahead*](#) (publicado en Junio de 2024), que para **2027**

(incluso antes de 2029) tendremos una **Inteligencia General Artificial (AGI)** y poco después una **Superinteligencia**, además dice que hay un crecimiento explosivo de la IA (predice que una vez tengamos una IA nivel ingeniero de IA (2027), esa IA investigará cómo hacer mejores IAs mucho más rápido que nosotros, comprimiendo 100 años de avance científico en 1 año).

- **Pregunta 6**

Si vuestro modelo nunca alcanza el umbral de calidad o seguridad que vosotros mismos establecéis, ¿qué plan de contingencia tenéis previsto?

Si no alcanzamos los umbrales de seguridad (Safety), la decisión ética y empresarial es clara: **No se lanza el producto (No-Go)**. No comprometeremos la seguridad por cumplir plazos. Nuestro plan de contingencia técnico consiste en la **reducción del alcance**. Si la manipulación compleja (cocinar) es demasiado peligrosa, lanzaremos una versión restringida centrada en navegación y vigilancia segura, funciones que son más fáciles de validar, mientras seguimos entrenando las capacidades motoras complejas en nuestro banco de pruebas físico *"The Gauntlet"*.

- **Pregunta 7**

Si vosotros mismos reconocéis que trabajáis con escenarios muy ambiciosos y difíciles de controlar, ¿cómo justificáis que esos requisitos sean realistas y alcanzables en vuestro horizonte temporal (2029)?

El horizonte 2029 es realista porque no dependemos de un "descubrimiento mágico", sino de la integración de tecnologías que ya existen hoy. Actualmente ya hay robots humanoides caminando y manipulando objetos (ej. Tesla Optimus, Figure). Nuestra innovación está en el **enfoque de seguridad y privacidad**. Además, el uso de entrenamiento masivo en simulación (Digital Twin) nos permite acumular "años" de experiencia de navegación en semanas de tiempo real, acelerando exponencialmente la curva de aprendizaje frente a las pruebas físicas tradicionales. Además, también lo justificamos con lo ya mencionado antes con artículos de expertos de renombre en la materia, [*Situational Awareness: The Decade Ahead*](#).

- **Pregunta 8**

Reconocéis lagunas en los datos disponibles y utilizáis datos generados artificialmente. ¿Cómo garantizáis que esta generación cubre efectivamente las carencias y no introduce nuevos sesgos o fallos?

No usamos datos sintéticos indiscriminadamente. Aplicamos una estrategia de **simulación a real con validación humana**. Generamos datos en simulación para cubrir escenarios de borde peligrosos (ej. un niño cayendo frente al robot) que no podemos grabar en la vida real por ética. Para evitar sesgos o alucinaciones de la simulación, validamos los modelos resultantes en *"The Gauntlet"* (pruebas físicas

reales) y auditamos las métricas de equidad (Fairness) para asegurar que la detección funciona igual en diferentes condiciones. Es un ciclo de mejora continua: simulación, prueba real, ajuste.

- **Pregunta 9**

¿Estáis dispuestos a permitir contribuciones de la comunidad en el código o en la documentación? ¿Podría la comunidad proponer nuevas funcionalidades o mejoras?

Valoramos el feedback de la comunidad para la detección de errores y sugerencias de usabilidad a través de nuestros canales de reclamación y App. Sin embargo, dado que ISA-Home es un **Sistema de Alto Riesgo** que opera maquinaria física junto a personas vulnerables, no podemos permitir contribuciones directas al código del núcleo de seguridad por parte de terceros no auditados. El código crítico debe permanecer cerrado y certificado para garantizar la responsabilidad civil y evitar inyecciones de código malicioso.

- **Pregunta 10**

Afirmáis que ISA-Home PRO no sustituirá al ser humano, pero no detalláis cómo se garantiza esa premisa. ¿Qué mecanismos o límites aseguran que el robot no reemplazará funciones humanas esenciales?

Garantizamos esto mediante **Líneas Rojas Éticas y Técnicas** definidas en el diseño del producto.

- **Límite Emocional:** Hemos prohibido explícitamente el reconocimiento de emociones y la simulación de afecto. ISA-Home es una herramienta, no un compañero social, evitando la dependencia psicológica.
- **Límite Funcional:** El robot está diseñado para tareas "sucias, aburridas y peligrosas" (limpieza, carga, vigilancia). No toma decisiones médicas ni sobre la educación de los menores. Su función es liberar tiempo al humano para que este pueda dedicarse a los cuidados de calidad, no sustituir el rol del cuidador o del padre.